

CAHIER DU PARTICIPANT · DATA SCIENCE

Workshop Data Science en autonomie

Une journée pour construire, seul·e et à ton rythme, un vrai projet data science. Choisis un thème, suis les consignes, aide-toi des indices — et n'ouvre la correction qu'après avoir essayé.

En solo, à ton rythme

1 thème au choix

Journée de 8 h

Consignes + indices

Ce cahier se suffit à lui-même : tout ce dont tu as besoin est dedans. Le code des solutions se trouve dans le document « Corrections », à consulter en dernier recours.

Comment utiliser ce cahier

Tu travailles seul·e : ce document est ton guide et ton filet de sécurité.

► Le principe

Tu choisis **un seul thème** et tu le construis en trois étapes de difficulté croissante :

- **Socle** — l'objectif à atteindre absolument.
- **Palier +** — pour enrichir ton projet.
- **Palier ++** — le défi, si tu vas vite.

► Chaque tâche contient

- **Une consigne** — ce que tu dois obtenir.
- **Des indices** — dévoile-les un par un si tu bloques.
- **Une auto-vérification** — pour savoir seul·e si c'est réussi.
- **Un renvoi** vers la correction si besoin.

La règle anti-blocage (importante en solo) : si tu restes coincé·e plus de **15 minutes** sur une tâche → 1) relis la consigne, 2) lis l'indice suivant, 3) et seulement après, ouvre la correction. L'objectif n'est pas de finir vite : c'est de comprendre ce que tu fais.

Avant de coder : ouvre le **starter kit** de ton thème (un notebook en ligne, sans rien à installer), et fais-le tourner tel quel une première fois. Tu dois voir les données s'afficher avant de commencer — c'est ton point de départ.

► Ce que ce workshop développe chez toi

Quel que soit le thème choisi, tu repartiras avec des compétences transversales du métier de data scientist :

COMPÉTENCES TRANSVERSALES

Cycle data de bout en bout

Préparation des données

Analyse & interprétation

Esprit critique

Travail en autonomie

Communication d'un résultat

OBJECTIFS DE LA JOURNÉE — À LA FIN, TU SERAS CAPABLE DE...

- ✓ partir de données brutes et les préparer pour les exploiter ;
- ✓ produire un livrable data science fonctionnel, seul·e ;
- ✓ expliquer ce que fait ta solution et en nommer les limites ;
- ✓ t'auto-évaluer et repérer ce qu'il te reste à approfondir.

Le déroulé de ta journée

Un rythme conseillé sur 8 h (09h00 → 17h00). Les horaires sont des repères, pas une contrainte — mais garde les objectifs de fin d'étape en tête.

Créneau	Durée	Ce que tu fais
MATINÉE		
09:00 – 09:30	30 min	Mise en route : lire ce cahier, choisir ton thème , ouvrir le starter kit et le faire tourner.
09:30 – 11:30	2 h	Étape 1 • Socle — construis la base de ton projet.
11:30 – 11:45	15 min	Pause écran.
11:45 – 12:30	45 min	Finir le socle + auto-vérification. Objectif : socle terminé avant midi.
PAUSE DÉJEUNER • 12:30 – 13:30		
APRÈS-MIDI		
13:30 – 15:15	1 h 45	Étape 2 • Palier + — enrichis ton projet. Objectif : palier + atteint vers 15h15.
15:15 – 15:30	15 min	Pause écran.
15:30 – 16:30	1 h	Étape 3 • Palier ++ — le défi (si tu as le temps ; sinon, consolide le palier +).
16:30 – 17:00	30 min	Finalisation, auto-évaluation (dernière page) et — si un partage est prévu — préparation d'un mini-résumé de ce que tu as fait.

Pas grave si tu n'atteins pas le palier ++. Un socle propre et bien compris vaut mieux qu'un palier ++ bâclé. Vise la qualité de ce que tu termines.

Choisir ton thème

Un seul à choisir. Prends celui qui t'attire le plus — les trois sont faisables en une journée.

Thème	Tu construis...	Idéal si...	Niveau
A • Recommandation « Netflix maison »	un moteur qui recommande des films à partir des goûts des utilisateurs.	tu aimes l'idée d'un système « intelligent » concret et parlant.	Intermédiaire
B • Détection d'anomalies « À la recherche du signal »	un détecteur qui repère les transactions suspectes dans un flux de données.	tu aimes l'esprit « enquête » : trouver ce qui cloche.	Intermédiaire
C • Data storytelling « Faire parler les données »	une petite histoire visuelle qui délivre un message clair à partir de données réelles.	tu débutes, ou tu préfères l'analyse et la communication au code lourd.	Accessible

Tu débutes vraiment ? Le thème C est le plus accessible et peut même se faire sans coder (tableur + outil de visualisation). Les thèmes A et B demandent un peu de Python, mais le starter kit et les indices te tiennent la main.

« Netflix maison » — Système de recommandation

À partir de notes d'utilisateurs sur des films, tu vas construire un moteur qui recommande.

Objectif final : pouvoir saisir un film (ou un utilisateur) et obtenir 5 recommandations crédibles.

DONNÉES

Notes de films (userId, movieId, note) + infos films (titre, genre).
Déjà chargées dans le starter kit.

OUTILS

Python · pandas · scikit-learn, dans le notebook en ligne. Rien à installer.

LIVRABLE

Une fonction qui renvoie 5 recommandations + 2-3 phrases expliquant ta logique.

COMPÉTENCES DÉVELOPPÉES

pandas (groupby, agg, filters)

matrice pivot

notion de similarité

filtrage collaboratif

similarité cosinus

évaluation d'un modèle

OBJECTIFS ATTEINTS — TU SAURAS...

- ✓ recommander par popularité et par similarité ;
- ✓ gérer le démarrage à froid et exclure les films déjà vus ;
- ✓ calculer une similarité cosinus entre films ;
- ✓ juger la qualité de tes recommandations.

ÉTAPE 1 Socle — recommander par popularité et similarité simple

objectif du matin

A.1 — Explorer les données

Affiche combien il y a d'utilisateurs, combien de films, et la note moyenne générale. Regarde à quoi ressemblent les premières lignes.

INDICE 1 Les fonctions `.nunique()`, `.mean()` et `.head()` de pandas te donnent tout ça.

VÉRIFIE Tu sais annoncer « il y a X utilisateurs, Y films, note moyenne $\approx$ Z ».

A.2 — Recommander les films les plus populaires

Renvoie les 5 films les mieux notés. Attention au piège : un film avec une seule note à 5/5 n'est pas « le meilleur ».

INDICE 1 Regroupe par film et calcule à la fois la *note moyenne* et le *nombre de notes* (`groupby` + `agg`).

INDICE 2 Ne garde que les films ayant au moins ~10 notes *avant* de trier par moyenne.

VÉRIFIE Tes 5 films ont tous une bonne moyenne *et* un nombre de votes raisonnable.

Bloqué-e ? → **Corrections, Thème A, tâche A.2**

A.3 — « Ceux qui ont aimé X ont aussi aimé... »

Pour un film donné, trouve les films que les mêmes amateurs ont aussi bien notés.

INDICE 1 Étape 1 : trouve les utilisateurs qui ont mis une bonne note (≥ 4) au film choisi.

INDICE 2 Étape 2 : parmi ces utilisateurs, compte les *autres* films qu'ils ont bien notés, et garde les plus fréquents.

VÉRIFIE Pour un film que tu connais, les suggestions te semblent-elles cohérentes ?

Bloqué-e ? → **Corrections, Thème A, tâche A.3**

ÉTAPE 2 Palier + — personnaliser et gérer les nouveaux venus

objectif d'après-midi

A.4 — Filtrer par genre

Permet de ne recommander que dans un genre choisi (Action, Comédie...).

INDICE Filtre d'abord la table des films sur le genre, puis applique ta reco par popularité à ce sous-ensemble.

VÉRIFIE En demandant « Comédie », tu n'obtiens que des comédies.

A.5 — Gérer un nouvel utilisateur (démarrage à froid)

Que recommander à quelqu'un dont on ne connaît aucun goût ? Propose les films les plus populaires de son genre préféré.

INDICE Tu réutilises A.4 : le « genre préféré » est la seule info qu'on demande au nouvel arrivant.

VÉRIFIE Ta fonction renvoie quelque chose de sensé même sans historique.

Bloqué-e ? → **Corrections, Thème A, tâche A.5**

A.6 — Ne pas re-recommander un film déjà vu

Exclus des suggestions les films que l'utilisateur a déjà notés.

INDICE Récupère la liste des `movieId` déjà notés par l'utilisateur et retire-les du résultat.

VÉRIFIE Aucun film déjà noté n'apparaît dans les recommandations.

ÉTAPE 3 Palier ++ — filtrage collaboratif & évaluation

le défi

A.7 — Similarité par cosinus

Construis une matrice utilisateurs × films et calcule la similarité entre films (cosinus). Recommande les films les plus proches de celui choisi.

INDICE 1 `pivot_table` pour la matrice, `.fillna(0)` pour les cases vides.

INDICE 2 `cosine_similarity` de scikit-learn s'applique sur la matrice transposée (films en lignes).

VÉRIFIE Les films « proches » d'un film donné sont plausibles.

Bloqué-e ? → **Corrections, Thème A, tâche A.7**

A.8 — Évaluer ton moteur

Cache quelques notes connues, demande une recommandation, et vérifie si le système « retrouve » ce que l'utilisateur aimait.

INDICE Pas besoin de métrique compliquée : compte, sur quelques exemples, combien de films aimés ré-apparaissent dans le top recommandé.

VÉRIFIE Tu peux dire « sur 5 tests, le bon film revient N fois » et en tirer une conclusion.

« À la recherche du signal » — Détection d'anomalies

Tu vas repérer les cas anormaux dans un flux de transactions : d'abord avec des règles simples, puis avec un vrai algorithme. Objectif final : un détecteur qui signale les cas suspects et que tu sais justifier.

DONNÉES

Transactions (montant, et éventuellement une étiquette fraude/normal). Déjà chargées dans le starter kit.

OUTILS

Python · pandas · matplotlib · scikit-learn. Notebook en ligne, rien à installer.

LIVRABLE

Un détecteur qui liste et visualise les cas anormaux + ta justification de méthode.

COMPÉTENCES DÉVELOPPÉES

exploration statistique

z-score & IQR

visualisation d'anomalies

réglage de sensibilité

Isolation Forest

matrice de confusion

OBJECTIFS ATTEINTS — TU SAURAS...

- ✓ définir ce qu'est un cas « normal » dans des données ;
- ✓ détecter des anomalies par deux méthodes différentes ;
- ✓ régler la sensibilité et comprendre le compromis alertes ;
- ✓ comparer une approche par règles à un modèle dédié.

ÉTAPE 1 Socle — détecter par règles statistiques

objectif du matin

B.1 — Décrire ce qui est « normal »

Explore les montants : moyenne, écart-type, valeurs min/max. Trace un histogramme.

INDICE `.describe()` te donne les stats, `.hist()` le graphique en une ligne.

VÉRIFIE Tu peux décrire à quoi ressemble une transaction typique.

B.2 — Détecter avec le z-score

Signale les montants qui s'écartent de plus de 3 écarts-types de la moyenne.

INDICE $z = (\text{montant} - \text{moyenne}) / \text{écart-type}$. Une anomalie = $\text{abs}(z) > 3$.

VÉRIFIE Tu obtiens un nombre plausible de cas signalés (pas 0, pas la moitié des données).

Bloqué-e ? → [Corrections, Thème B, tâche B.2](#)

B.3 — Détecter avec la méthode des quartiles (IQR)

Signale les montants en dehors de l'intervalle habituel défini par les quartiles. Compare avec le z-score.

INDICE Q1 et Q3 via `.quantile([.25, .75])`, puis borne basse = $Q1 - 1.5 \times IQR$, borne haute = $Q3 + 1.5 \times IQR$.

VÉRIFIE Tu peux dire combien de cas chaque méthode signale et en quoi elles diffèrent.

Bloqué-e ? → **Corrections, Thème B, tâche B.3**

ÉTAPE 2 Palier + — visualiser et régler la sensibilité

objectif d'après-midi

B.4 — Rendre les anomalies visibles

Trace les données en mettant en évidence (couleur différente) les points signalés comme anormaux.

INDICE Trace deux nuages de points superposés : les points normaux, puis les anormaux dans une autre couleur.

VÉRIFIE Les points anormaux « sautent aux yeux » sur ton graphique.

B.5 — Jouer sur le seuil

Fais varier le seuil (par ex. 2, 2.5, 3 écarts-types) et observe l'effet sur le nombre d'alertes.

INDICE Boucle sur quelques seuils et affiche, pour chacun, le nombre de cas signalés.

VÉRIFIE Tu comprends le compromis : seuil bas = plus d'alertes (dont fausses), seuil haut = on rate des cas.

B.6 — Mesurer si des étiquettes existent

Si le jeu de données indique les vraies fraudes, compte combien tu en attrapes et combien de fausses alertes tu génères.

INDICE `confusion_matrix` de scikit-learn compare tes alertes aux vraies étiquettes.

VÉRIFIE Tu sais dire : « j'attrape X vraies fraudes, j'en rate Y, et je déclenche Z fausses alertes ».

Bloqué-e ? → **Corrections, Thème B, tâche B.6**

ÉTAPE 3 Palier ++ — modèle dédié & comparaison

le défi

B.7 — Isolation Forest

Utilise un algorithme de détection d'anomalies et compare ses résultats à tes règles du socle.

INDICE 1 `IsolationForest(contamination=0.05)` , puis `fit_predict` — les anomalies sont marquées `-1` .

INDICE 2 Refais une matrice de confusion pour comparer avec B.6.

VÉRIFIE Tu peux dire si le modèle fait mieux, moins bien, ou différemment des règles.

Bloqué-e ? → [Corrections, Thème B, tâche B.7](#)

« Faire parler les données » — Data storytelling

À partir de données réelles, tu vas construire une petite histoire visuelle qui délivre un message clair. Objectif final : 3 à 5 visualisations qui, ensemble, prouvent quelque chose.

DONNÉES

Un jeu de données ouvertes au choix (transport, santé, environnement...). Fourni dans le starter kit.

OUTILS

Au choix : Python + pandas, *ou* tableur + outil de visualisation (sans code).

LIVRABLE

3 à 5 slides (ou un notebook) : Constat → Preuve → Message.
Bonus : un tableau de bord interactif.

COMPÉTENCES DÉVELOPPÉES

nettoyage de données

visualisations lisibles

croisement de variables

variable calculée & tendance

tableau de bord interactif

communication d'un message

OBJECTIFS ATTEINTS — TU SAURAS...

- ✓ nettoyer un jeu de données réel ;
- ✓ produire des visualisations qui portent un message ;
- ✓ croiser des dimensions et nuancer honnêtement ;
- ✓ assembler un tableau de bord interactif.

ÉTAPE 1 Socle — nettoyer et poser un constat

objectif du matin

C.1 — Nettoyer les données

Repère et traite les valeurs manquantes, les doublons et les formats bizarres.

INDICE `.isna().sum()` pour repérer les trous, `.dropna()` ou remplissage, `.drop_duplicates()` pour les doublons.

VÉRIFIE Plus de valeurs manquantes non traitées, plus de doublons.

C.2 — Trois visualisations lisibles

Produis 3 graphiques : chacun doit avoir un titre clair, des axes légendés, et pas de surcharge.

INDICE Un graphique = une idée. Choisis le bon type : courbe pour une évolution, barres pour comparer, camembert seulement si peu de parts.

VÉRIFIE Quelqu'un qui découvre ton graphique comprend le message sans explication orale.

Bloqué-e ? → **Corrections, Thème C, tâche C.2**

C.3 — Formuler ton constat

Écris en une phrase ce que tes trois graphiques établissent.

INDICE Le test : « ces données montrent que _____ ». Si tu n'arrives pas à remplir le blanc, tes graphiques ne racontent pas encore d'histoire.

VÉRIFIE Ta phrase est vraie, précise, et soutenue par tes graphiques.

ÉTAPE 2 Palier + — croiser pour faire émerger un sens

objectif d'après-midi

C.4 — Croiser deux dimensions

Combine deux variables (ex. région × année) pour révéler un contraste ou une tendance qu'on ne voyait pas.

INDICE `pivot_table` (ou un tableau croisé dynamique dans un tableur) fait exactement ça.

VÉRIFIE Le croisement montre quelque chose de nouveau par rapport à l'étape 1.

Bloqué-e ? → **Corrections, Thème C, tâche C.4**

C.5 — Nuancer honnêtement

Ajoute une phrase de prudence : corrélation n'est pas causalité, et cite une limite de tes données.

INDICE Demande-toi : « qu'est-ce que quelqu'un pourrait me reprocher sur cette conclusion ? »

VÉRIFIE Ton histoire reste honnête : elle n'affirme pas plus que ce que les données prouvent.

ÉTAPE 3 Palier ++ — variable calculée, tendance & tableau de bord

le défi

C.6 — Créer une variable calculée

Fabrique une mesure plus parlante que les données brutes : un taux, un ratio, une valeur par habitant.

INDICE Une division bien choisie (dépense ÷ population) rend souvent les comparaisons bien plus justes.

VÉRIFIE Ta nouvelle variable change (ou affine) la lecture par rapport aux données brutes.

Bloqué-e ? → **Corrections, Thème C, tâche C.6**

C.7 — Ajouter une tendance et conclure

Trace une tendance sur tes données dans le temps, et assemble le tout en un fil narratif « et donc ? ».

INDICE Une simple droite de tendance suffit ; l'important est l'enchaînement Constat → Preuve → Message.

VÉRIFIE En lisant tes slides dans l'ordre, on suit une histoire, pas une pile de graphiques.

C.8 — LE DÉFI : un tableau de bord interactif

Rassemble ton travail dans un **tableau de bord** : au moins un **filtre** (par région ou par année), **2-3 indicateurs clés** (chiffres importants) et tes graphiques, le tout se mettant à jour quand on change le filtre.

INDICE · SANS CODE Avec **Looker Studio** (gratuit) : connecte ton fichier nettoyé, ajoute des graphiques, un bloc « statistique » pour chaque indicateur, puis un *contrôle de filtre* lié à la région ou l'année.

INDICE · AVEC CODE Avec **Streamlit** : `st.selectbox` pour le filtre, `st.metric` pour les indicateurs, `st.line_chart` / `st.bar_chart` pour les graphes. Tout ce qui dépend du filtre se recalcule automatiquement.

VÉRIFIE Quand tu changes le filtre (ex. tu passes de « Toutes » à une région), **tous** les indicateurs et graphiques se mettent à jour ensemble.

Bloqué·e ? → **Corrections, Thème C, tâche C.8**

Auto-évaluation de fin de journée

Coche ce que tu as réussi. C'est ta boussole — pas une note.

Pour tous les thèmes

- ☐ J'ai fait tourner le starter kit et compris les données de départ.
- ☐ J'ai terminé **tout le socle** et je sais expliquer ce qu'il fait.
- ☐ J'ai atteint au moins une tâche du **palier +**.
- ☐ Je peux résumer mon projet en 3 phrases à quelqu'un d'autre.
- ☐ Je sais nommer une limite de ce que j'ai produit.
- ☐ (*Bonus*) J'ai touché au **palier ++**.

Pour aller plus loin après le workshop : reprends la première tâche que tu as dû regarder dans la correction, et refais-la sans regarder. C'est là que se joue l'apprentissage réel.

Rappel : le code complet de chaque tâche marquée « Bloqué·e ? » se trouve dans le document **Corrections**. Utilise-le pour comprendre, pas pour copier.